CHƯƠNG 2: Exploring and Processing Text Data

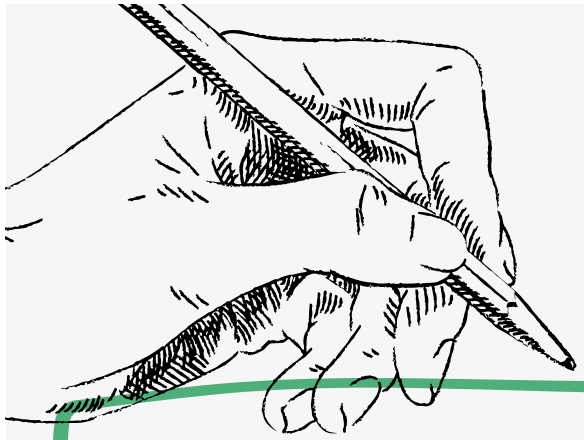

Tiền xử lí văn bản: data có thể đến từ nhiều dạng như ảnh, âm thanh, văn bản, video. Trong đó text với từ riêng lẽ, câu, đoạn với kí tự đặc biệt, hay web, html, document... Tiền xử lí giúp làm sạch nhiễu lỗi, giúp các thuật toán áp dụng trên nó đưa ra giá trị tốt hơn

VẤN ĐỀ

Viết thường văn bản

XỬ LÝ

Sử dụng hàm lower()

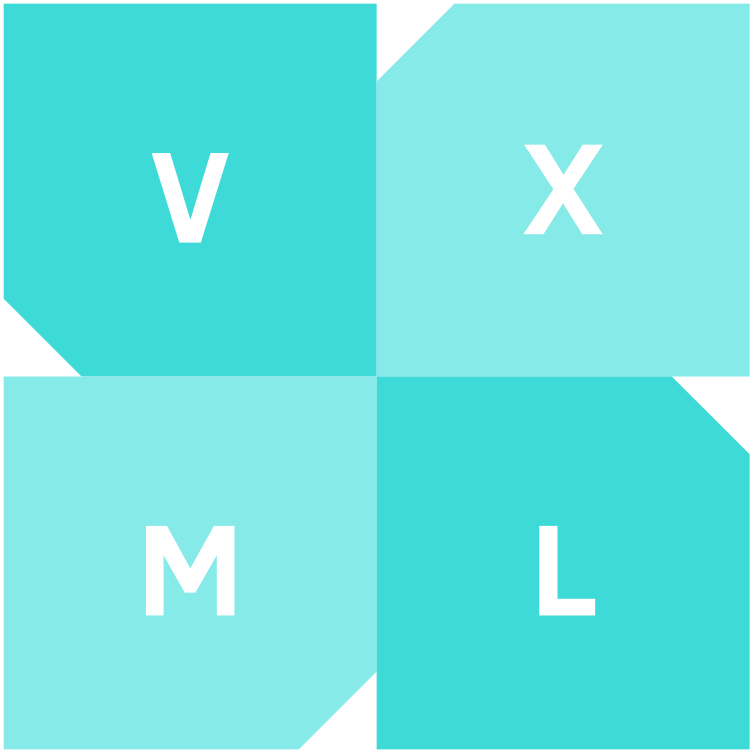

LOWERCASE

MỤC ĐÍCH

Chuyển văn bản về các từ viết thường nhằm mục đích xử lí dữ liệu về sau

LOWERCASING

```python
#lower
x = 'Testing'
x2 = x.lower()
print(x2)
```

```
testing
```

```python
text=['This is introduction to NLP','It is likely to be useful, to people ','Machine learning is the new electrcity', 'There would be less hype around AI and mor
import pandas as pd
df = pd.DataFrame({'tweet':text})
print(df)
df['tweet'] = df['tweet'].apply(lambda x: " ".join(x.lower() for x in x.split()))
print("Lower:")
df['tweet']
```

```
                                              tweet
0                        This is introduction to NLP
1              It is likely to be useful, to people
2             Machine learning is the new electrcity
3  There would be less hype around AI and more ac...
4                           python is the best tool!
5                                R is good langauage
6                                   I like this book
7                        I want more books like this
Lower:
0                          this is introduction to nlp
1                 it is likely to be useful, to people
2               machine learning is the new electrcity
3    there would be less hype around ai and more ac...
4                             python is the best tool!
5                                  r is good langauage
6                                     i like this book
7                          i want more books like this
Name: tweet, dtype: object
```

VẤN ĐỀ

Loại bỏ dấu chấm câu trong văn bản

XỬ LÝ

Sử dụng hàm replace()
Sử dụng regex

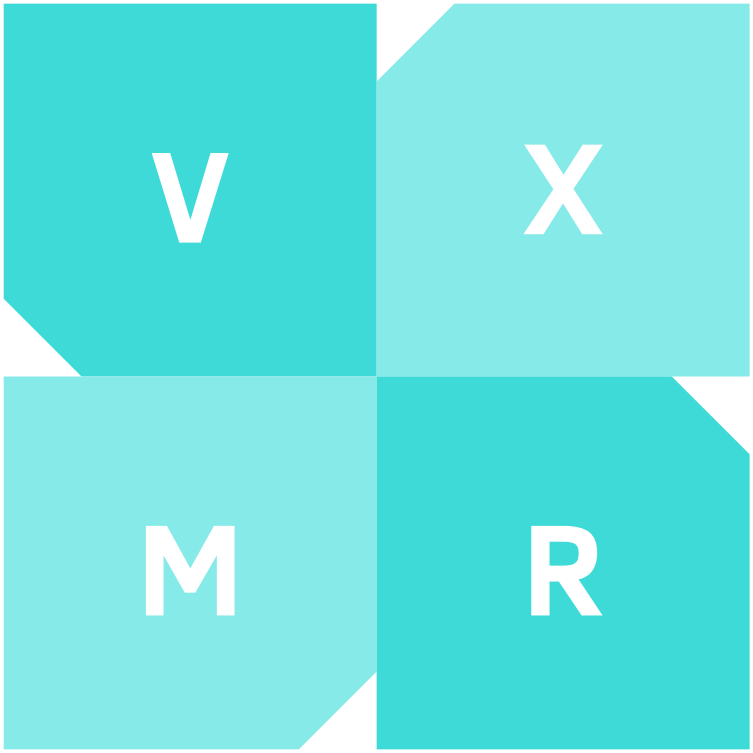

MỤC ĐÍCH

Xoá dấu câu. Vì dấu câu cho ta lại thông gì hết.
Giúp giảm kích cỡ dữ liệu.
Tăng hiệu suất

REMOVING PUNCTUATION

PUNCTUATION REMOVAL

```
df['tweet'] = df['tweet'].str.replace('[^\w\s]','')
df['tweet']
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:8

0                          This is introduction to NLP
1                 It is likely to be useful to people
2               Machine learning is the new electrcity
3    There would be less hype around AI and more ac...
4                               python is the best tool
5                                   R is good langauage
6                                      I like this book
7                          I want more books like this
Name: tweet, dtype: object
```

REMOVING STOP WORDS

VẤN ĐỀ

Loại bỏ từ xuất hiện nhiều nhưng không có nội dung trong văn bản

XỬ LÝ

Sử dụng thư viện NLTK

MỤC ĐÍCH

Tập trung vào những từ, ký tự có nghĩa nhất trong văn bản. Giúp trả về kết quả tốt hơn

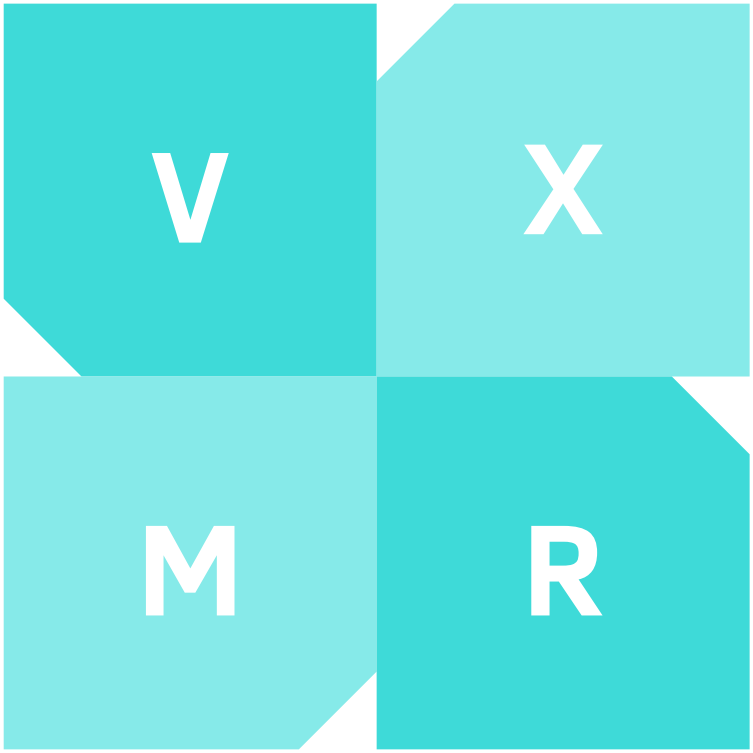

STOP WORDS REMOVAL

```
!pip install nltk
import nltk
nltk.download('stopwords')
from nltk.corpus import stopwords
#remove stop words
stop = stopwords.words('english')
df['tweet'] = df['tweet'].apply(lambda x: " ".join(x for x in x.split() if x not in stop))
df['tweet']
```

```
Requirement already satisfied: nltk in /usr/local/lib/python3.7/dist-packages (3.2.5)
Requirement already satisfied: six in /usr/local/lib/python3.7/dist-packages (from nltk) (1.15.0)
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data]   Package stopwords is already up-to-date!
0                                This introduction NLP
1                              It likely useful people
2                      Machine learning new electrcity
3    There would less hype around AI action going f...
4                                     python best tool
5                                     R good langauage
6                                          I like book
7                                    I want books like
Name: tweet, dtype: object
```

Stop words

VẤN ĐỀ

Chuyển đổi những từ mà người dùng viết tắt về từ chuẩn.

XỬ LÝ

Viết một danh sách từ điển riêng chứa các từ viết tắt..

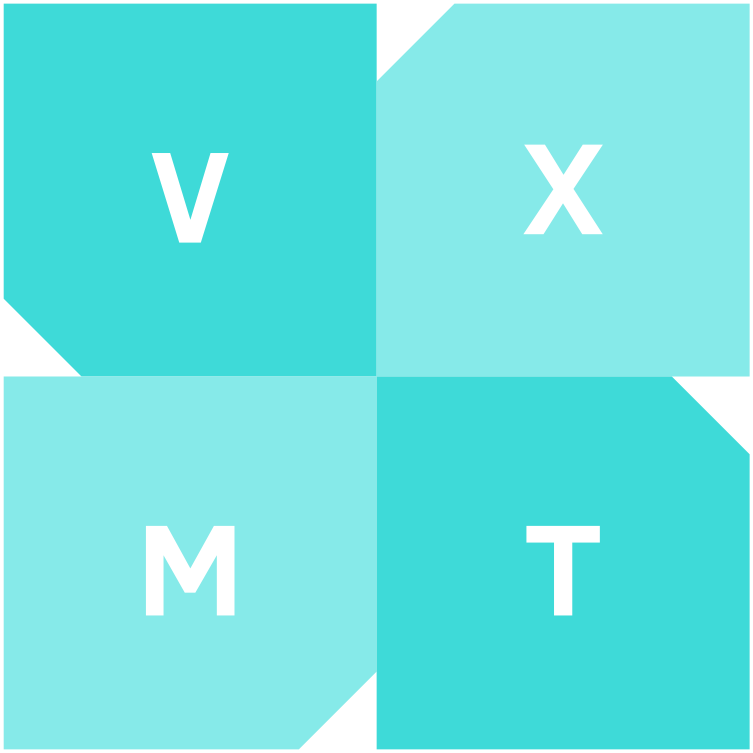

MỤC ĐÍCH

Chuẩn hóa văn bản

TEXT STANDARDIZATION

TEXT STANDARDIZATION

```
#Standardizing Text

lookup_dict = {'nlp':'natural language processing', 'ur':'your', "wbu" : "what about you"}
import re

def text_std(input_text):
 words = input_text.split()
 new_words = []
 for word in words:
  word = re.sub(r'[^\w\s]','',word)
  if word.lower() in lookup_dict:
    word = lookup_dict[word.lower()]
    new_words.append(word)
    new_text = " ".join(new_words)
 return new_text

text_std("I like nlp it's ur choice")
```

```
'natural language processing your'
```

VẤN ĐỀ

Sửa lỗi chính tả trong văn bản

XỬ LÝ

Sử dụng thư viện TextBlob library

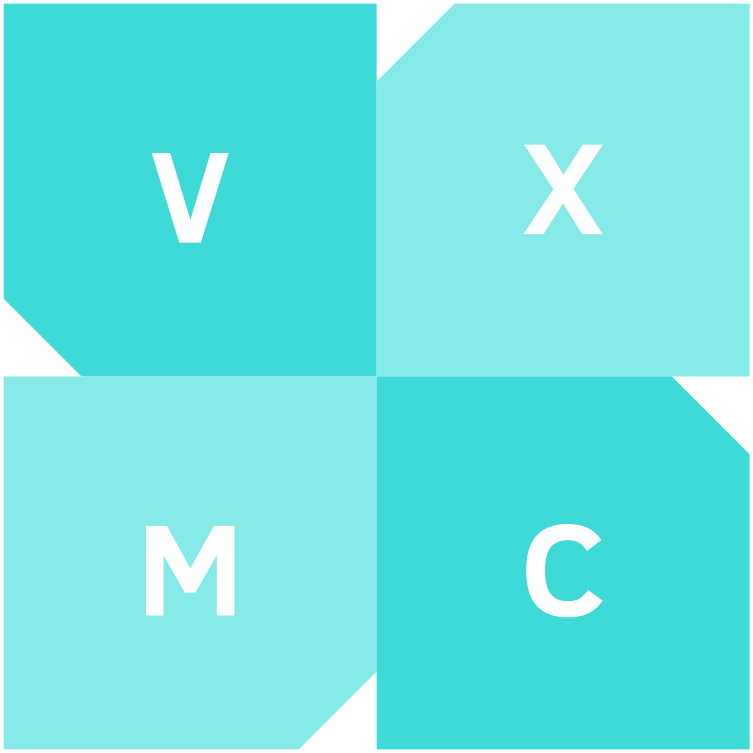

MỤC ĐÍCH

Sửa lỗi chính tả, lỗi type. Đây là một bước quan trọng trong tiền xử lý văn bản

CORRECTING SPELLING

SPELLING CORRECTION

```
#correcting spelling

#Install textblob library
!pip install textblob
#import libraries and use 'correct' function
from textblob import TextBlob
df['tweet'].apply(lambda x: str(TextBlob(x).correct()))

!pip install autocorrect
from autocorrect import spell
print(spell(u'mussage'))
print(spell(u'sirvice'))
```

Input

"mussage"
"sirvice"

Output

"message"
"service"

```
autocorrect.spell is deprecated,
message
autocorrect.spell is deprecated,
service
```

SPELLING CORRECTION

```python
import pandas as pd
text=['Introduction to NLP',
    'It is likely to be useful, to people ',
    'Machine learning is the new electrcity',
    'R is good langauage',
    'I like this book',
    'I want more books like this']
#convert list to dataframe
df = pd.DataFrame({'tweet':text})
print(df)
```

Tạo dữ liệu

```
                                    tweet
0                     Introduction to NLP
1   It is likely to be useful, to people
2  Machine learning is the new electrcity
3                     R is good langauage
4                        I like this book
5             I want more books like this
```

SPELLING CORRECTION

```python
import pandas as pd
from textblob import TextBlob

text=['Introduction to NLP',
    'It is likely to be useful, to people ',
    'Machine learning is the new electrcity',
    'R is good langauage',
    'I like this book',
    'I want more books like this']
#convert list to dataframe
df = pd.DataFrame({'tweet':text})
df['tweet'] = df['tweet'].apply(lambda x: str(TextBlob(x).correct()))
print(df)
```

Dữ liệu đã được sửa lỗi chính tả

```
0                        Introduction to NLP
1     It is likely to be useful, to people
2   Machine learning is the new electricity
3                         R is good language
4                           I like this book
5                I want more books like this
```

"electrcity" => "electricy"
"langauage" => "language"

TOKENIZATION

VẤN ĐỀ

Mã hóa văn bản

XỬ LÝ

Sử dụng thư viện TextBlob

MỤC ĐÍCH

Mã hoá chia văn bản thành những đơn vị nhỏ hơn vẫn có nghĩa. Đây là bước bắt buộc trong quá trình tiền xử lý văn bản cho bất kỳ loại phân tích nào.

TOKENIZATION

```
#tokeninzing text

#Using textblob
# from textblob import TextBlob
# TextBlob(df['tweet'][3]).words

#using NLTK
import nltk
nltk.download('punkt')
#create data
mystring = "My favorite animal is cat"
nltk.word_tokenize(mystring)

#using split function from python
mystring.split()
```

```
[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data]   Unzipping tokenizers/punkt.zip.
['My', 'favorite', 'animal', 'is', 'cat']
```

VẤN ĐỀ

Trích xuất ra từ gốc

XỬ LÝ

Sử dụng thư viện TextBlob hoặc thư viện NLTK

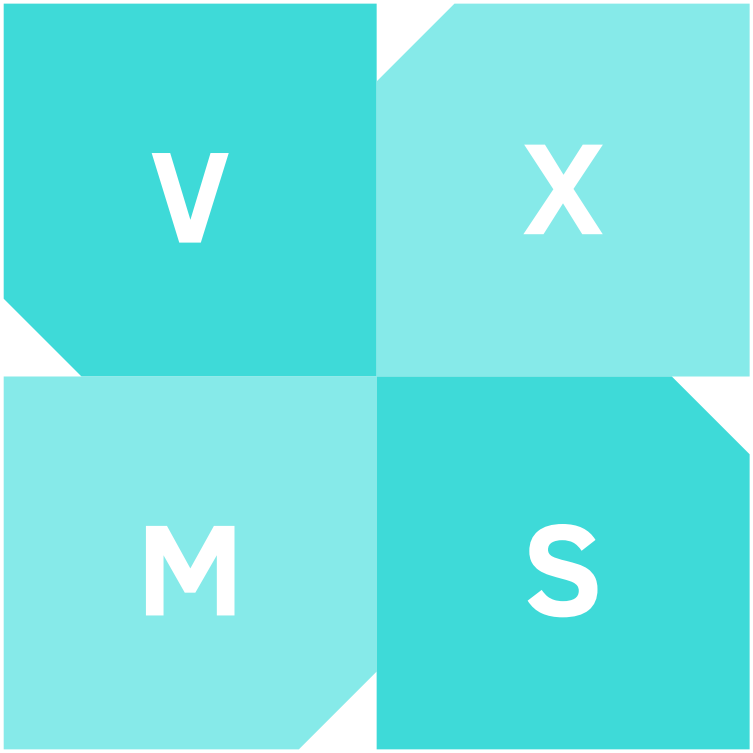

STEMMING

MỤC ĐÍCH

Trích ra từ gốc. Ví dụ: fish, fishing, fished được tạo ra từ fish

STEMMING

```python
#stemming

text=['I like fishing','I eat fish','There are many fishes in pound']
#convert list to dataframe
import pandas as pd
t = pd.DataFrame({'tweet':text})
print(t)

#Import library
from nltk.stem import PorterStemmer
st = PorterStemmer()
t['tweet'][:5].apply(lambda x: " ".join([st.stem(word) for word in x.split()]))
```

```
                          tweet
0                 I like fishing
1                     I eat fish
2  There are many fishes in pound
0                    I like fish
1                     I eat fish
2    there are mani fish in pound
Name: tweet, dtype: object
```

Stemming

VẤN ĐỀ

Trích xuất ra từ gốc

XỬ LÝ

Sử dụng thư viện TextBlob hoặc thư viện NLTK

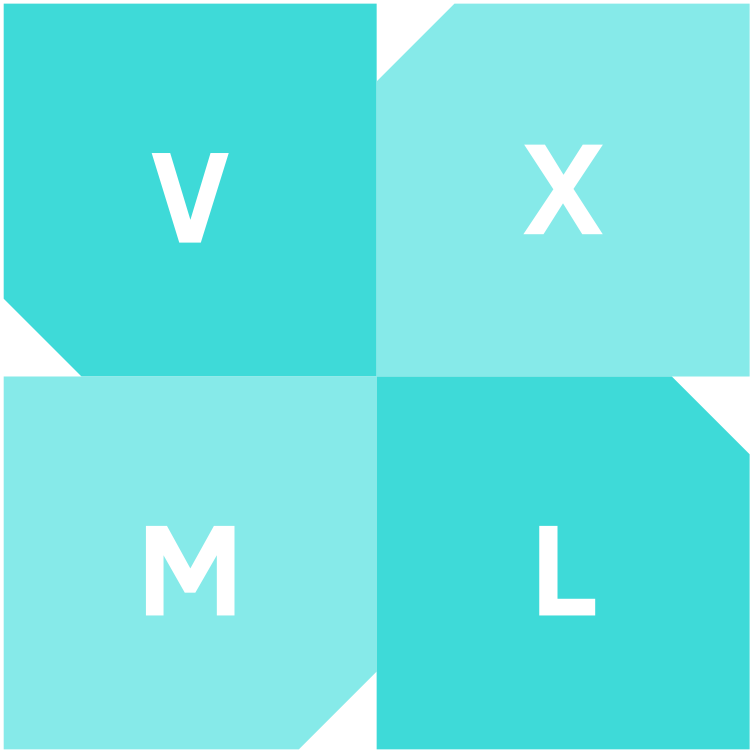

MỤC ĐÍCH

Trích ra từ gốc bằng cách duyệt từ vựng. Khác ở trên. Ví dụ: Better, best, good được hình thành từ "good"

LEMMENTIZATION

LEMMATIZATION

```python
#Lemmatizing
text=['I like fishing','I eat fish','There are many fishes in pound', 'leaves and leaf']
#convert list to dataframe
import pandas as pd
lemmatize = pd.DataFrame({'tweet':text})
print(lemmatize)

import nltk
nltk.download('wordnet')

from textblob import Word
#Code for lemmatize
lemmatize['tweet'] = lemmatize['tweet'].apply(lambda x: " ".join([Word(word).lemmatize() for word in x.split()]))
lemmatize['tweet']
```

```
                          tweet
0                 I like fishing
1                     I eat fish
2  There are many fishes in pound
3                 leaves and leaf
[nltk_data] Downloading package wordnet to /root/nltk_data...
[nltk_data]   Unzipping corpora/wordnet.zip.
0                 I like fishing
1                     I eat fish
2   There are many fish in pound
3                  leaf and leaf
```

Lemmatizing cho kết quả tốt hơn stemming

VẤN ĐỀ

Khám phá và hiểu hơn về văn bản

XỬ LÝ

Sử dụng thư viện TextBlob hoặc thư viện NLTK

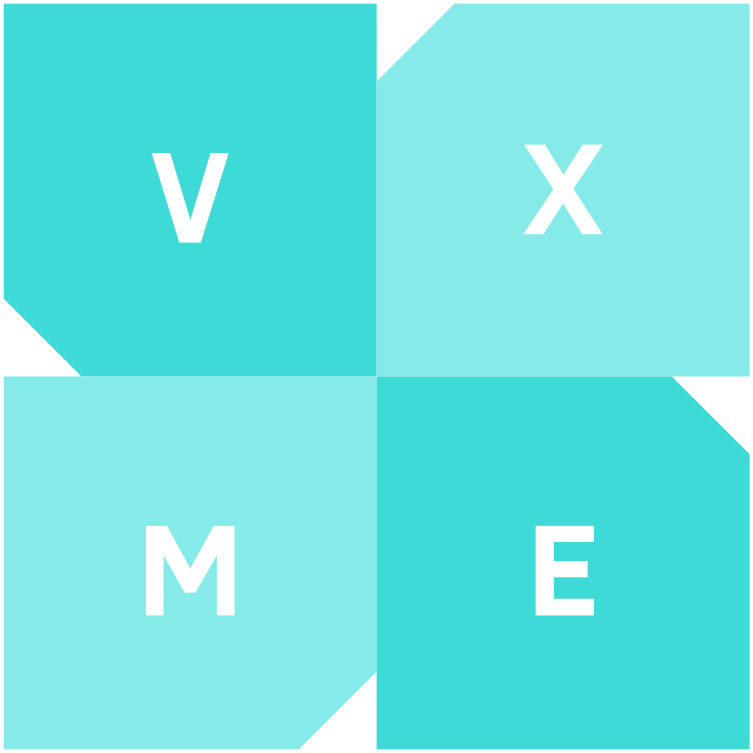

MỤC ĐÍCH

Đến đây, ta đã làm qua nhiều bước tiền xử lý. Bây giờ ta có thể thực hiện phân tích khai phá dữ liệu

EXPLORING TEXT DATA

EXPLORATORY DATA ANALYSIS

```python
#exploring text data
nltk.download()
#Importing data
import nltk
from nltk.corpus import webtext
nltk.download('webtext')
wt_sentences = webtext.sents('firefox.txt')
wt_words = webtext.words('firefox.txt')

from nltk.probability import FreqDist
from nltk.corpus import stopwords
import string

print(len(wt_sentences))
print(len(wt_words))
```

Số lượng các từ

```
1142
102457
```

EXPLORATORY DATA ANALYSIS

```
#Compute the frequency of all words in the reviews

frequency_dist = nltk.FreqDist(wt_words)
frequency_dist

sorted_frequency_dist =sorted(frequency_dist,key=frequency_dist.__getitem__, reverse=True)
sorted_frequency_dist
```

List các từ xuất hiện thường xuyên

```
'is',
't',
'and',
'of',
'(',
'page',
'for',
'with',
')',
'window',
'Firefox',
```

EXPLORATORY DATA ANALYSIS

```
#exploring data (cont.)
# Consider words with length greater than 3 and plot

large_words = dict([(k,v) for k,v in frequency_dist.items() if len(k)>3])
frequency_dist = nltk.FreqDist(large_words)
frequency_dist.plot(50,cumulative=False)
```

Biểu đồ tần suất xuất hiện của các từ có độ dài lớn hơn 3

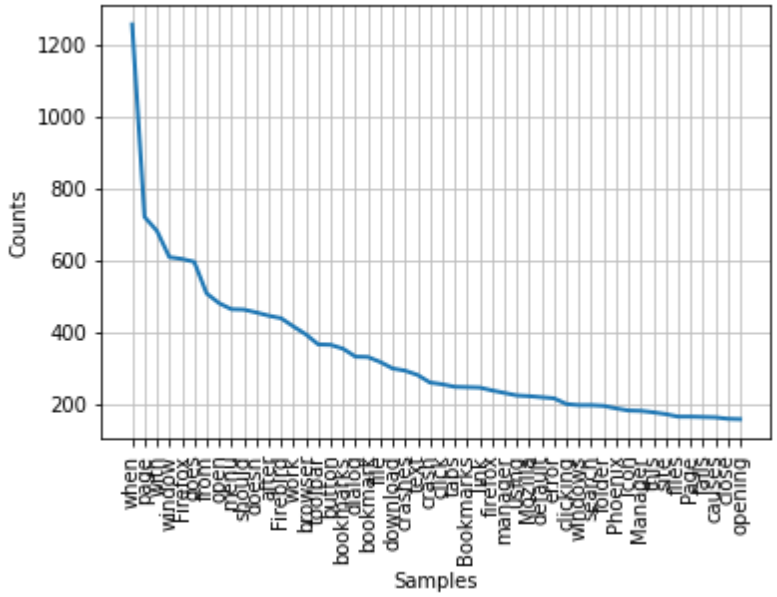

EXPLORATORY DATA ANALYSIS

```
#Build Wordcloud

!pip install wordcloud
#build wordcloud
from wordcloud import WordCloud
wcloud = WordCloud().generate_from_frequencies(frequency_dist)

#plotting the wordcloud
import matplotlib.pyplot as plt
plt.imshow(wcloud, interpolation='bilinear')
plt.axis("off")
(-0.5, 399.5, 199.5, -0.5)
plt.show()
```

Tạo Word Cloud để biểu diễn trực quan, các từ xuất hiện càng nhiều thì kích thước càng lớn

BUILDING A TEXT PROCCESSING PIPELINE

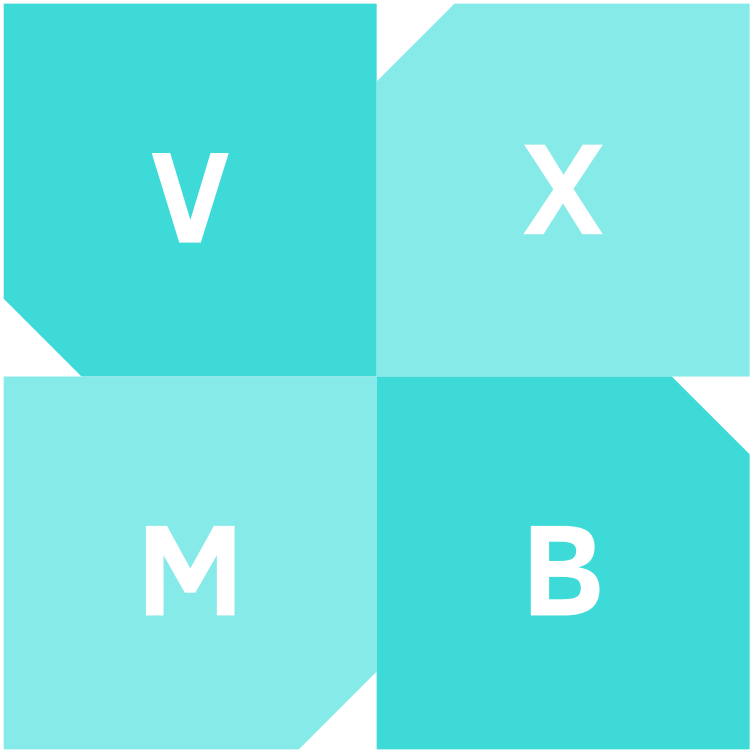

VẤN ĐỀ

Làm điều gì đó thú vị sau hoàn thiện hầu hết các kỹ thuật và ph. Trong công thức này, hãy làm điều gì đó thú vị.

XỬ LÝ

tạo hàm tùy chỉnh với tất cả các kỹ thuật đã học cho đến nay.

MỤC ĐÍCH

Bạn muốn xây dựng một đường dẫn tiền xử lý văn bản end-to-end. Bất cứ khi nào bạn muốn thực hiện tiền xử lý cho bất kỳ ứng dụng NLP nào, bạn có thể trực tiếp cắm dữ liệu vào chức năng đường ống này và lấy dữ liệu văn bản sạch cần thiết làm đầu ra.

BUILDING A TEXT PREPROCESSING PIPELINE

INPUT: How to take control of your #debt https://personal.vanguard.com/us/insights/saving-investing/debt management.#Best advice for #family #financial #success (@PrepareToWin)"

```
#Lower case
tweet.lower()
#Removes unicode strings like "\u002c" and "x96"
tweet = re.sub(r'(\\u[0-9A-Fa-f]+)',r'', tweet)
tweet = re.sub(r'[^\x00-\x7f]',r'',tweet)
#convert any url to URL
tweet = re.sub('((www\.[^\s]+)|(https?://[^\s]+))','URL',tweet)
#Convert any @Username to "AT_USER"
tweet = re.sub('@[^\s]+','AT_USER',tweet)
#Remove additional white spaces
tweet = re.sub('[\s]+', ' ', tweet)
tweet = re.sub('[\n]+', ' ', tweet)
#Remove not alphanumeric symbols white spaces
tweet = re.sub(r'[^\w]', ' ', tweet)
#Removes hastag in front of a word """
tweet = re.sub(r'#([^\s]+)', r'\1', tweet)
```

```
#Replace #word with word
tweet = re.sub(r'#([^\s]+)', r'\1', tweet)
#Remove :( or :)
tweet = tweet.replace(':)','')
tweet = tweet.replace(':(','')
#remove numbers
tweet = ''.join([i for i in tweet if not i.isdigit()])
#remove multiple exclamation
tweet = re.sub(r"(\!)\1+", ' ', tweet)
#remove multiple question marks
tweet = re.sub(r"(\?)\1+", ' ', tweet)
#remove multistop
tweet = re.sub(r"(\.)\1+", ' ', tweet)
#lemma
from textblob import Word
tweet =" ".join([Word(word).lemmatize() for word in tweet.split()])
```

```
#remove emoticons
tweet=re.sub(':\)|;\)|:-\)|\(-:|:-D|=D|:P|xD|X-p|\^\^|:-*|\^\.\^|\^\-\^|\^\_\^|\,-\)|\)-:|:\'\(|:\(|:-\(|:\S|T\.T|\.\_\.|:<|:-\S|:-<|\*\-\*|:O|=O|=\-O|O\.o|XO|O\_O|:-\@|=/|:/|X\-\(|>\.<|>=\(|D:', '', tweet)
#trim
tweet = tweet.strip('\'"')
```

Output

```
'How to take control of your debt URL debt management Best advice for family financial success AT_USER'
```

Không còn URL và các ký tự đặc biệt

Thank you!